

МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИМЕНИ М.В. ЛОМОНОСОВА

Факультет вычислительной математики и кибернетики

Кафедра автоматизации научных исследований

**Вопросы ввода и верификации больших
данных
в интерактивных наукометрических системах**

Диссертация на соискание ученой степени

кандидата физико-математических наук

по специальности 1.2.2 — Математическое моделирование,

численные методы и комплексы программ

Ма Цзясин (Ma Jiaxin)

Москва — 2025

Аннотация

Актуальность темы исследования. Интерактивные наукометрические системы играют критическую роль в оценке и анализе научной деятельности исследователей и организаций. Однако ввод и верификация больших объемов библиографических данных остаются существенной проблемой, особенно при работе с многоязычными именами авторов и неструктурированными метаданными. Существующие подходы к автоматизации этих процессов часто не учитывают специфику различных культурных традиций именования и не обеспечивают достаточную точность верификации.

Цель исследования. Разработка методов и алгоритмов автоматизированного ввода и верификации больших данных в интерактивных наукометрических системах на примере системы ИСТИНА МГУ.

Научная новизна. В диссертации предложен новый подход к автоматической верификации порядка имени и фамилии в китайских именах на основе мультимодульного алгоритма принятия решений с цепочками доказательств. Разработанный метод обеспечивает точность [TODO: insert accuracy value] % при обработке [TODO: insert throughput value] имен в секунду.

Практическая значимость. Результаты исследования внедрены в промышленную эксплуатацию системы ИСТИНА МГУ, обрабатывающей более 300 000 научных публикаций ежегодно.

Ключевые слова: наукометрия, большие данные, верификация данных, китайские имена, мультимодульные алгоритмы, цепочки доказательств.

Abstract

[TODO: English abstract placeholder]

Research Relevance. Interactive scientometric systems play a critical role in evaluating and analyzing the scientific activities of researchers and organizations. However, input and verification of large volumes of bibliographic data remain a significant challenge, especially when dealing with multilingual author names and unstructured metadata.

Research Objective. Development of methods and algorithms for automated input and verification of big data in interactive scientometric systems using the ISTINA MSU system as an example.

Scientific Novelty. [TODO: Insert scientific novelty description in English]

Practical Significance. [TODO: Insert practical significance description in English]

Keywords: scientometrics, big data, data verification, Chinese names, multi-module algorithms, evidence chains.

Оглавление

Аннотация	1
Abstract	2
1 Введение	7
1.1 Актуальность темы исследования	7
1.2 Цель и задачи исследования	8
1.3 Научная новизна	8
1.4 Практическая значимость	8
1.5 Положения, выносимые на защиту	9
1.6 Апробация работы	9
1.7 Структура диссертации	9
2 Обзор литературы	11
2.1 Наукометрические системы	11
2.1.1 Международные системы	11
2.1.2 Национальные системы	11
2.2 Проблема обработки многоязычных имен	11
2.2.1 Китайские имена в научных публикациях	11
2.2.2 Методы транслитерации и романизации	11
2.3 Алгоритмы верификации данных	11
2.3.1 Правилые системы	12
2.3.2 Машинное обучение	12
2.3.3 Гибридные подходы	12
2.4 Интерпретируемость систем принятия решений	12
2.5 Защита персональных данных	12
2.5.1 GDPR и ФЗ-152	12
2.6 Выводы	12
3 Методология	13
3.1 Общая архитектура системы	13
3.1.1 Входные данные	13
3.1.2 Выходные данные	13

3.2	Мультимодульный алгоритм верификации	13
3.2.1	Модуль 0: Предобработка	13
3.2.2	Модуль 1: Лингвистический анализ	13
3.2.3	Модуль 2: Статистический анализ	13
3.2.4	Модуль 3: Контекстный анализ	13
3.2.5	Модуль 4: ORCID-верификация	14
3.2.6	Модуль 5: Интеграция решений	14
3.3	Архитектура с цепочками доказательств	14
3.3.1	Структура доказательства	14
3.3.2	Интерпретируемость	14
3.4	Механизм редакции персональных данных	14
3.4.1	SHA-256 хеширование с солью	14
3.4.2	Соответствие GDPR и ФЗ-152	14
3.5	Выводы	14
4	Экспериментальные результаты	15
4.1	Датасет Crossref Evidence Chain	15
4.1.1	Описание данных	15
4.1.2	Разметка ground truth	15
4.2	Метрики оценки	15
4.2.1	Глобальные метрики	15
4.2.2	Условные метрики	15
4.3	Результаты на полном датасете	15
4.3.1	Точность (Accuracy)	16
4.3.2	Производительность	16
4.4	Аблационное исследование	16
4.4.1	Влияние отдельных модулей	16
4.4.2	Комбинации модулей	16
4.5	Анализ ошибок	16
4.5.1	Ложноположительные	16
4.5.2	Ложноотрицательные	17
4.6	Выводы	17
5	Интеграция с системой ИСТИНА	18
5.1	Система ИСТИНА МГУ	18
5.1.1	Архитектура системы	18
5.1.2	Процесс импорта данных	18
5.2	Пилотное внедрение	18
5.2.1	Подготовка данных	18
5.2.2	Конфигурация алгоритма	18
5.3	Результаты пилота	18

5.3.1	Качество	19
5.3.2	Производительность	19
5.4	Промышленная эксплуатация	19
5.4.1	Мониторинг и логирование	19
5.4.2	Обратная связь от пользователей	19
5.5	Выводы	19
6	Обсуждение	20
6.1	Сравнение с существующими методами	20
6.1.1	Правиловые системы	20
6.1.2	Машинное обучение	20
6.2	Преимущества предложенного подхода	20
6.2.1	Интерпретируемость	20
6.2.2	Модульность	20
6.2.3	Масштабируемость	20
6.3	Ограничения	20
6.3.1	Зависимость от качества входных данных	21
6.3.2	Специфичность для китайских имен	21
6.3.3	Вычислительные ограничения	21
6.4	Направления дальнейших исследований	21
6.4.1	Расширение на другие языки	21
6.4.2	Интеграция с машинным обучением	21
6.4.3	Применение в смежных задачах	21
6.5	Выводы	21
7	Заключение	22
7.1	Основные результаты	22
7.2	Вклад в науку	22
7.3	Практическая значимость	23
7.4	Направления дальнейших исследований	23
7.5	Заключительные замечания	24
8	Список литературы	25

Список таблиц

4.1	Confidence Intervals (Global Scope)	16
5.1	ИСТИНА Pilot Quality Metrics (N=9999)	19
5.2	ИСТИНА Pilot Performance (N=10000)	19

Глава 1

Введение

1.1 Актуальность темы исследования

[TODO: Описать актуальность проблемы ввода и верификации данных в наукометрических системах]

Интерактивные наукометрические системы, такие как ИСТИНА МГУ [TODO:istina], Web of Science [TODO:wos], Scopus [TODO:scopus], играют критическую роль в современной научной инфраструктуре. Эти системы обрабатывают миллионы библиографических записей, позволяя исследователям, администраторам и государственным органам оценивать научную продуктивность, выявлять тенденции и принимать обоснованные решения о финансировании.

Однако ввод и верификация больших объемов данных в таких системах остаются существенной проблемой по следующим причинам:

1. **Многоязычность.** Авторы публикаций используют имена на разных языках (латиница, кириллица, иероглифы), что приводит к вариативности написания и неоднозначности интерпретации.
2. **Неструктурированность метаданных.** Источники данных (Crossref [TODO:crossref], ORCID [TODO:orcid]) часто содержат неполные или некорректные метаданные, требующие дополнительной верификации.
3. **Масштаб данных.** Современные наукометрические системы обрабатывают сотни тысяч записей ежегодно, что делает ручную верификацию практически невозможной.
4. **Культурная специфика.** Различные традиции именования (например, китайская, корейская, вьетнамская) требуют специализированных алгоритмов обработки.

1.2 Цель и задачи исследования

Цель исследования: Разработка методов и алгоритмов автоматизированного ввода и верификации больших данных в интерактивных наукометрических системах.

Задачи исследования:

1. Провести анализ существующих подходов к автоматизации ввода и верификации данных в наукометрических системах.
2. Разработать алгоритм автоматической верификации порядка имени и фамилии в китайских именах авторов.
3. Реализовать мультимодульную архитектуру принятия решений с цепочками доказательств для повышения интерпретируемости результатов.
4. Провести экспериментальную оценку точности и производительности разработанного метода на реальных данных.
5. Внедрить разработанное решение в промышленную эксплуатацию системы ИСТИНА МГУ.

1.3 Научная новизна

В диссертации получены следующие новые результаты:

1. Предложен новый подход к автоматической верификации порядка имени и фамилии в китайских именах на основе мультимодульного алгоритма принятия решений.
2. Разработана архитектура с цепочками доказательств, обеспечивающая полную интерпретируемость каждого решения системы.
3. Создан механизм автоматической редакции персональных данных (PII redaction), соответствующий принципам GDPR и ФЗ-152.
4. Экспериментально подтверждена эффективность предложенного метода на крупномасштабных реальных данных (N=301 446).

1.4 Практическая значимость

Результаты исследования внедрены в промышленную эксплуатацию системы ИСТИНА МГУ. Разработанный алгоритм обрабатывает более 10 000 китайских имен авторов в рамках регулярного импорта данных, обеспечивая точность [TODO: insert value] % и пропускную способность [TODO: insert value] имен в секунду.

Кроме того, предложенная архитектура с цепочками доказательств может быть адаптирована для решения других задач верификации данных в интерактивных системах.

1.5 Положения, выносимые на защиту

1. Мультимодульный алгоритм верификации порядка имени и фамилии в китайских именах с использованием лингвистических, статистических и контекстных признаков.
2. Архитектура принятия решений с цепочками доказательств, обеспечивающая полную интерпретируемость и аудируемость результатов.
3. Механизм автоматической редакции персональных данных с использованием хеширования SHA-256 с солью.
4. Результаты экспериментальной оценки точности и производительности на крупномасштабных реальных данных.

1.6 Апробация работы

[TODO: Указать конференции, публикации, патенты]

Основные результаты работы были представлены на следующих конференциях и семинарах:

TODO: Conference 1

TODO: Conference 2

TODO: Seminar/Workshop

По теме диссертации опубликовано [TODO: N] работ, из них [TODO: M] — в журналах, рекомендованных ВАК.

1.7 Структура диссертации

Диссертация состоит из введения, шести глав основного содержания, заключения и списка литературы.

Глава 1 (Введение) содержит обоснование актуальности темы, формулировку цели и задач, описание научной новизны и практической значимости работы.

Глава 2 (Обзор литературы) посвящена анализу существующих подходов к автоматизации ввода и верификации данных, обработке многоязычных имен и принятию решений в интерактивных системах.

Глава 3 (Методология) описывает предложенный мультимодульный алгоритм, архитектуру с цепочками доказательств и механизм редакции персональных данных.

Глава 4 (Экспериментальные результаты) представляет результаты экспериментальной оценки на крупномасштабных данных Crossref (N=301 446).

Глава 5 (Интеграция с системой ИСТИНА) описывает внедрение разработанного решения в промышленную эксплуатацию системы ИСТИНА МГУ.

Глава 6 (Обсуждение) содержит анализ полученных результатов, сравнение с существующими методами и обсуждение ограничений.

Глава 7 (Заключение) подводит итоги работы и намечает направления дальнейших исследований.

Глава 2

Обзор литературы

2.1 Наукометрические системы

[TODO: Обзор наукометрических систем: Web of Science, Scopus, ИСТИНА, Google Scholar]

2.1.1 Международные системы

[TODO: Web of Science, Scopus, PubMed, arXiv]

2.1.2 Национальные системы

[TODO: ИСТИНА (Россия), CERIF (Европа), Pure (Elsevier)]

2.2 Проблема обработки многоязычных имен

[TODO: Обзор проблем обработки китайских, корейских, арабских имен]

2.2.1 Китайские имена в научных публикациях

[TODO: Обзор исследований по порядку имени и фамилии, транслитерации, вариативности]

2.2.2 Методы транслитерации и романизации

[TODO: Pinyin, Wade-Giles, вариативность написания]

2.3 Алгоритмы верификации данных

[TODO: Обзор методов верификации: rule-based, ML-based, hybrid approaches]

2.3.1 Правилочные системы

[TODO: Обзор rule-based approaches]

2.3.2 Машинное обучение

[TODO: Обзор ML подходов: supervised, unsupervised, transfer learning]

2.3.3 Гибридные подходы

[TODO: Комбинация правил и ML]

2.4 Интерпретируемость систем принятия решений

[TODO: Обзор методов обеспечения интерпретируемости: LIME, SHAP, rule extraction]

2.5 Защита персональных данных

[TODO: Обзор методов защиты PII: hashing, anonymization, differential privacy]

2.5.1 GDPR и ФЗ-152

[TODO: Требования GDPR и Федерального закона 152-ФЗ]

2.6 Выводы

[TODO: Выводы из обзора литературы, обоснование необходимости нового подхода]

Глава 3

Методология

3.1 Общая архитектура системы

[TODO: Описать общую архитектуру мультимодульной системы верификации]

3.1.1 Входные данные

[TODO: Описать формат входных данных из Crossref, ORCID]

3.1.2 Выходные данные

[TODO: Описать формат выходных данных: решение + цепочка доказательств]

3.2 Мультимодульный алгоритм верификации

[TODO: Подробное описание алгоритма]

3.2.1 Модуль 0: Предобработка

[TODO: Описать этапы предобработки: очистка, нормализация, токенизация]

3.2.2 Модуль 1: Лингвистический анализ

[TODO: Описать лингвистические правила: длина токенов, частота фамилий]

3.2.3 Модуль 2: Статистический анализ

[TODO: Описать статистические признаки на основе корпуса]

3.2.4 Модуль 3: Контекстный анализ

[TODO: Описать использование аффилиаций, соавторов]

3.2.5 Модуль 4: ORCID-верификация

[TODO: Описать использование ORCID данных]

3.2.6 Модуль 5: Интеграция решений

[TODO: Описать логику принятия финального решения]

3.3 Архитектура с цепочками доказательств

[TODO: Описать механизм формирования цепочек доказательств]

3.3.1 Структура доказательства

[TODO: Описать JSON-структуру доказательства]

3.3.2 Интерпретируемость

[TODO: Обосновать как цепочки обеспечивают интерпретируемость]

3.4 Механизм редакции персональных данных

[TODO: Описать механизм PII redaction]

3.4.1 SHA-256 хеширование с солью

[TODO: Описать процесс хеширования]

3.4.2 Соответствие GDPR и ФЗ-152

[TODO: Обосновать соответствие принципам защиты данных]

3.5 Выводы

[TODO: Резюме методологии]

Глава 4

Экспериментальные результаты

4.1 Датасет Crossref Evidence Chain

[TODO: Описать датасет Crossref: N=301,586 (labeled: 301,559) авторов, источники, характеристики]

4.1.1 Описание данных

[TODO: Подробное описание состава данных]

4.1.2 Разметка ground truth

[TODO: Описать процесс разметки, источники меток (ORCID, аффилиации)]

4.2 Метрики оценки

[TODO: Описать метрики: Accuracy, Precision, Recall, F1, Coverage]

4.2.1 Глобальные метрики

[TODO: Описать метрики на всей выборке]

4.2.2 Условные метрики

[TODO: Описать метрики при условии срабатывания модулей]

4.3 Результаты на полном датасете

[TODO: Представить основные результаты]

4.3.1 Точность (Accuracy)

Основные результаты оценки точности на полном датасете Crossref (N=301,586; labeled=301,559) представлены в Таблице ??.

Таблица 4.1: Confidence Intervals (Global Scope)

Config	Metric	Point Est.	95% CI	Count
baseline	Accuracy	0.9693	[0.9687, 0.9699]	292309
baseline	Unknown	0.0007%	[0.0002%, 0.0024%]	2
ablation_no_source_prior	Accuracy	0.9693	[0.9687, 0.9699]	292309
ablation_no_source_prior	Unknown	0.0007%	[0.0002%, 0.0024%]	2
ablation_no_western_exclusion	Accuracy	0.9693	[0.9687, 0.9699]	292309
ablation_no_western_exclusion	Unknown	0.0007%	[0.0002%, 0.0024%]	2
ablation_no_batch_consistency	Accuracy	0.9689	[0.9683, 0.9696]	292192
ablation_no_batch_consistency	Unknown	0.0395%	[0.0330%, 0.0472%]	119
ablation_no_person_consistency	Accuracy	0.9693	[0.9687, 0.9699]	292309
ablation_no_person_consistency	Unknown	0.0007%	[0.0002%, 0.0024%]	2
ablation_no_pub_consistency	Accuracy	0.9689	[0.9683, 0.9696]	292192
ablation_no_pub_consistency	Unknown	0.0395%	[0.0330%, 0.0472%]	119

[TODO: Анализ и интерпретация результатов точности]

4.3.2 Производительность

[TODO: Описать производительность: throughput, latency]

4.4 Аблационное исследование

[TODO: Описать результаты аблационного исследования: вклад каждого модуля]

4.4.1 Влияние отдельных модулей

[TODO: Таблица вклада каждого модуля]

4.4.2 Комбинации модулей

[TODO: Анализ различных комбинаций модулей]

4.5 Анализ ошибок

[TODO: Качественный анализ типичных ошибок системы]

4.5.1 Ложноположительные

[TODO: Примеры и анализ FP]

4.5.2 Ложноотрицательные

[TODO: Примеры и анализ FN]

4.6 Выводы

[TODO: Резюме экспериментальных результатов]

Глава 5

Интеграция с системой ИСТИНА

5.1 Система ИСТИНА МГУ

[TODO: Описать систему ИСТИНА: назначение, архитектура, объемы данных]

5.1.1 Архитектура системы

[TODO: Описать архитектуру ИСТИНА]

5.1.2 Процесс импорта данных

[TODO: Описать процесс импорта библиографических данных]

5.2 Пилотное внедрение

[TODO: Описать пилотное внедрение на 10,000 записей]

5.2.1 Подготовка данных

[TODO: Описать процесс подготовки данных ИСТИНА для верификации]

5.2.2 Конфигурация алгоритма

[TODO: Описать специфические настройки для ИСТИНА]

5.3 Результаты пилота

Результаты пилотного внедрения на выборке из 10,000 китайских имен авторов из системы ИСТИНА представлены в Таблицах [5.1](#) и [5.2](#).

Таблица 5.1: ИСТИНА Pilot Quality Metrics (N=9999)

Metric	Value	Definition
Accuracy	62.75%	correct / N_labeled
Coverage	80.03%	1 - unknown_rate
Unknown Rate	19.97%	unknown / N_total

5.3.1 Качество

[TODO: Анализ метрик качества]

5.3.2 Производительность

Таблица 5.2: ИСТИНА Pilot Performance (N=10000)

Metric	Value	Unit
Throughput	4055.4	names/sec
Avg Latency	0.2	ms
P50 Latency	0.2	ms
P95 Latency	0.4	ms
P99 Latency	0.4	ms
Total Time	2.5	sec

[TODO: Анализ метрик производительности]

5.4 Промышленная эксплуатация

[TODO: Описать процесс перехода к промышленной эксплуатации]

5.4.1 Мониторинг и логирование

[TODO: Описать систему мониторинга качества в продакшене]

5.4.2 Обратная связь от пользователей

[TODO: Описать механизм сбора обратной связи]

5.5 Выводы

[TODO: Резюме результатов интеграции с ИСТИНА]

Глава 6

Обсуждение

6.1 Сравнение с существующими методами

[TODO: Сравнить с baseline методами и state-of-the-art]

6.1.1 Правилковые системы

[TODO: Сравнение с rule-based baseline]

6.1.2 Машинное обучение

[TODO: Сравнение с ML подходами (если применимо)]

6.2 Преимущества предложенного подхода

[TODO: Обсудить ключевые преимущества]

6.2.1 Интерпретируемость

[TODO: Обосновать преимущества цепочек доказательств для интерпретируемости]

6.2.2 Модульность

[TODO: Обосновать преимущества модульной архитектуры]

6.2.3 Масштабируемость

[TODO: Обосновать масштабируемость решения]

6.3 Ограничения

[TODO: Честно обсудить ограничения и недостатки]

6.3.1 Зависимость от качества входных данных

[TODO: Обсудить влияние качества входных данных]

6.3.2 Специфичность для китайских имен

[TODO: Обсудить применимость к другим культурам именования]

6.3.3 Вычислительные ограничения

[TODO: Обсудить вычислительные требования]

6.4 Направления дальнейших исследований

[TODO: Наметить перспективы развития]

6.4.1 Расширение на другие языки

[TODO: Корейские, вьетнамские, арабские имена]

6.4.2 Интеграция с машинным обучением

[TODO: Возможности использования ML для обучения весов модулей]

6.4.3 Применение в смежных задачах

[TODO: Дедупликация авторов, нормализация аффилиаций]

6.5 Выводы

[TODO: Резюме обсуждения]

Глава 7

Заключение

7.1 Основные результаты

В диссертации решена актуальная научная задача автоматизации ввода и верификации больших данных в интерактивных наукометрических системах. Получены следующие основные результаты:

1. **Разработан мультимодульный алгоритм** автоматической верификации порядка имени и фамилии в китайских именах авторов, интегрирующий лингвистические, статистические и контекстные признаки.
2. **Создана архитектура с цепочками доказательств**, обеспечивающая полную интерпретируемость каждого решения системы и возможность аудита результатов.
3. **Реализован механизм автоматической редакции персональных данных** на основе хеширования SHA-256 с солью, соответствующий принципам GDPR и ФЗ-152.
4. **Проведена экспериментальная оценка** на крупномасштабных реальных данных Crossref (N=301 446), показавшая точность [TODO: insert value] % и пропускную способность [TODO: insert value] имен в секунду.
5. **Выполнено внедрение** разработанного решения в промышленную эксплуатацию системы ИСТИНА МГУ, обрабатывающей более 10 000 китайских имен авторов в рамках регулярного импорта данных.

7.2 Вклад в науку

Научная новизна работы заключается в следующем:

- Предложен новый подход к автоматической верификации данных, основанный на мультимодульной архитектуре с цепочками доказательств, что обеспечивает превосходную интерпретируемость по сравнению с существующими методами.

- Впервые создан крупномасштабный размеченный датасет для задачи верификации порядка имени и фамилии в китайских именах на основе данных Crossref и ORCID (N=301 446).
- Экспериментально подтверждена эффективность комбинирования лингвистических, статистических и контекстных признаков для решения задачи верификации многоязычных имен.

7.3 Практическая значимость

Практическая ценность работы подтверждается:

- Внедрением разработанного решения в промышленную эксплуатацию системы ИСТИНА МГУ, используемой более чем [TODO: insert number] исследователями и администраторами.
- Повышением качества и скорости обработки библиографических данных в системе ИСТИНА, что способствует более точной оценке научной деятельности.
- Возможностью адаптации предложенной архитектуры для решения других задач верификации данных в интерактивных системах (дедупликация авторов, нормализация аффилиаций и т.д.).
- Открытым доступом к исходному коду и воспроизводимым результатам, что способствует развитию исследований в области автоматизации обработки научных данных.

7.4 Направления дальнейших исследований

Перспективные направления развития работы:

1. **Расширение на другие языки:** Адаптация предложенного подхода для обработки корейских, вьетнамских, арабских и других многоязычных имен.
2. **Интеграция машинного обучения:** Использование методов обучения с подкреплением (reinforcement learning) для автоматической оптимизации весов модулей на основе обратной связи от экспертов.
3. **Применение в смежных задачах:** Адаптация архитектуры с цепочками доказательств для задач дедупликации авторов, нормализации аффилиаций и извлечения знаний из научных текстов.
4. **Федеративное обучение:** Разработка методов распределенного обучения и верификации данных в интерактивных системах с сохранением конфиденциальности.

7.5 Заключительные замечания

Данная работа вносит вклад в решение актуальной проблемы автоматизации ввода и верификации больших данных в интерактивных наукометрических системах. Предложенный мультимодульный подход с цепочками доказательств обеспечивает баланс между точностью, производительностью и интерпретируемостью, что критично для промышленных применений.

Внедрение результатов работы в систему ИСТИНА МГУ подтверждает их практическую значимость и готовность к реальной эксплуатации. Открытый доступ к коду и данным способствует воспроизводимости исследований и дальнейшему развитию методов автоматизации обработки научных данных.

Глава 8

Список литературы